Сибирский федеральный университет
Гуманитарный институт
Без кафедры

РЕФЕРАТ

по дисциплине «Информационные системы и технологии»
на тему:

Технологии создания и обработки текстовых документов

Выполнили: Делали: Бородина Алиса Андреевна, Шеломенцева Екатерина,...
Группа: ГФ26-02Б
Проверил: Нигматулин Илья Рафаилович

Красноярск, 2026

Содержание

1. Введение 3
2. Основная часть 3
   2.1. Кодирование текстовых данных: от национальных кодировок к Unicode 3
   2.2. Проприетарные и открытые форматы текстовых документов: совместимость и долговечность 5

1. Введение

Текстовый документ — это не просто последовательность букв на экране. Это сложная информационная структура, которая прошла долгий путь эволюции от глиняных табличек и пергаментов до цифровых файлов, обрабатываемых нейросетями. В современном мире технологии создания и обработки текста лежат в основе документооборота, образования, программирования и коммуникации. За привычным для пользователя действием — набором текста в редакторе и нажатием кнопки «Сохранить» — скрывается целый стек технологий: от аппаратного кодирования символов до алгоритмов семантического анализа. Актуальность темы обусловлена стремительным развитием систем искусственного интеллекта и необходимостью понимания того, как именно машины обрабатывают, хранят и интерпретируют текстовые данные.

Цель работы — комплексное изучение технологий создания и обработки текстовых документов, а также выявление ключевых тенденций и проблем в этой области.

Для достижения цели необходимо решить следующие задачи:

- рассмотреть эволюцию кодирования текстовых данных от национальных кодировок до стандарта Unicode;
- провести сравнительный анализ проприетарных и открытых форматов текстовых документов;
- изучить принципы языков разметки и концепцию разделения структуры и оформления;
- определить роль метаданных и семантической разметки для машинной обработки текста;
- проанализировать методы автоматической обработки текста и границы их достоверности;
- исследовать стратегии и форматы долговременного хранения и архивации текстовых ресурсов.

2. Основная часть

2.1. Кодирование текстовых данных: от национальных кодировок к Unicode

Любой текст в компьютере — это последовательность битов (нулей и единиц). Чтобы машина могла отобразить букву, этой букве должен

быть присвоен уникальный числовой код. Процесс присвоения таких кодов и называется кодированием.

Эпоха национальных кодировок Исторически первые компьютеры создавались для работы с латиницей. Стандарт **ASCII** (American Standard Code for Information Interchange), разработанный в 1960-х годах, использовал 7 бит для кодирования 128 символов: заглавные и строчные латинские буквы, цифры, знаки препинания и управляющие символы. Этого хватало для английского языка, но было абсолютно недостаточно для других.

С распространением компьютеров по миру возникла проблема локализации. Для каждого языка (русского, японского, арабского) создавались свои **национальные кодировки**. В России и СССР наибольшее распространение получили такие таблицы, как **CP1251** (Windows-1251), **KOI8-R** и **DOS-кодировка (CP866)**. В каждой из них одному и тому же числу (например, байту 192) соответствовали разные символы. Это породило знаменитую проблему «кракозябр» (или «крякозябр») — искажения текста, когда файл, созданный в одной кодировке, открывался программой, настроенной на другую. Главным ограничением национальных кодировок было то, что они использовали 8 бит (256 символов), и этого объема едва хватало для одного алфавита, не говоря уже о совмещении языков в одном документе.

Революция Unicode Решением проблемы стала универсальная система кодирования **Unicode**. Ее главная идея заключается в том, что каждому символу любого письменного языка мира (а также математическим знакам, эмодзи и историческим письменностям) присваивается уникальный номер — «кодовая точка». На сегодняшний день в Unicode закодировано более 149 000 символов.

Однако Unicode — это не сам формат хранения. Для записи этих кодов в файлы используются различные схемы кодирования, самые популярные из которых:

- **UTF-32** — использует фиксированные 4 байта на каждый символ. Надежно, но очень расточительно по памяти.
- **UTF-16** — использует 2 или 4 байта. Применяется во внутренних механизмах Windows, Java и .NET.
- **UTF-8** — переменная длина от 1 до 4 байт. Самый популярный стандарт в интернете. Его гениальность в обратной совместимости с ASCII: латинские буквы и базовые символы занимают

всего 1 байт, а редкие иероглифы или кириллица — больше. Это позволяет экономить место при хранении англоязычных текстов и при этом сохранять полную универсальность.

2.2. Проприетарные и открытые форматы текстовых документов: совместимость и долговечность

После того как текст закодирован, он должен быть сохранен в виде файла. Способ организации данных внутри файла называется **форматом**. Выбор формата — это стратегическое решение, влияющее на совместимость и сохранность информации.

Проприетарные (закрытые) форматы — это форматы, спецификация которых принадлежит конкретной компании. Самый яркий пример — семейство форматов **Microsoft Word (DOC, DOCX)**. Их плюсы очевидны: богатейший функционал, поддержка сложного форматирования, макросов, встроенных таблиц и графики. Однако у них есть существенный недостаток — «вендор-лок» (привязка к производителю). Если вы перестанете оплачивать подписку на офисный пакет или компания-разработчик изменит спецификацию, ваши документы могут стать недоступными или откроются с искажениями. Ярким примером является формат **Adobe PDF** (Portable Document Format). Изначально он был закрытым, но в 2008 году Adobe открыла спецификацию, и сегодня PDF является открытым стандартом (ISO 32000), что сделало его универсальным языком для обмена документами.

Открытые форматы — это форматы, спецификация которых опубликована и доступна для свободного использования. К ним относятся **TXT** (простой текст), **HTML** (веб-документы), **Markdown** (текстовая разметка) и **ODF (OpenDocument Format, например, ODT)**. Их главное преимущество — независимость от конкретного программного обеспечения. Вы можете открыть файл ODT в LibreOffice, Google Docs или любом другом редакторе, и он отобразится одинаково.

Совместимость и долговечность. Для обычного пользователя разница невелика, но для архивов и корпораций она критична. Проприетарные форматы сложны и меняются от версии к версии, что затрудняет их долгосрочное чтение. Открытые форматы, особенно простые (вроде TXT или XML-подобных структур), гораздо более долговечны: их можно прочитать даже без специального программного обеспечения, просто заглянув в исходный код файла. Именно поэтому в государ-

ственных архивах и библиотеках мира приоритет отдается открытым стандартам.