Сибирский федеральный университет

Гуманитарный институт

Информационные технологии в

РЕФЕРАТ

по дисциплине «Информационные системы и технологии в креативных и культурных индустриях»

на тему:

Технологии создания и обработки табличных данных

Выполнили: Стрельская Екатерина Евгеньевна, Рыженкова Ксения Максимовна, Новикова Виктория Александровна, Савельева Анна

Группа: ГФ26-02Б

Проверил: Нигматулин Илья Рафаилович

Красноярск, 2026

Содержание

1. Введение 3
2. Основная часть 3
   2.1. Структура табличных данных: принципы организации для машинной обработки 3
   2.2. Форматы хранения и обмена: риски потерь при конвертации 4

1. Введение

Табличные данные — одна из базовых форм представления информации в информационных системах и технологиях. Электронные таблицы и форматы обмена табличными данными (CSV, XLSX, JSON) используются повсеместно: от учебной и исследовательской работы до корпоративной отчётности и обмена с веб-сервисами. При этом именно табличные данные наиболее уязвимы к ошибкам организации, конвертации, визуализации и автоматизации расчётов: неверная структура листа, потеря типов при экспорте в CSV, смещение колонок из-за разделителей или ошибка в ссылке формулы способны сделать выводы недостоверными. Актуальность темы определяется необходимостью систематизировать принципы корректной работы с табличными данными на всех этапах — от создания до подготовки к анализу.

Цель работы — рассмотреть технологии создания и обработки табличных данных и сформулировать практические рекомендации по организации, хранению, визуализации, автоматизации расчётов и очистке табличных данных.

Для достижения цели необходимо решить следующие задачи:

- описать принципы организации структуры табличных данных для машинной обработки;
- сопоставить форматы хранения и обмена табличными данными и выявить риски потерь при конвертации;
- определить условия выбора формы визуализации и источники искажений;
- раскрыть принципы контроля ошибок при работе с формулами и функции;
- охарактеризовать этапы очистки и подготовки данных к анализу;
- оценить возможности и пределы применения электронных таблиц в учебной и исследовательской работе.

2. Основная часть

2.1. Структура табличных данных: принципы организации для машинной обработки

Для машинной обработки таблица должна быть организована как реляционная структура: каждая строка — наблюдение (запись), каждый столбец —

переменная (атрибут), а на пересечении — одно значение. Это базовое требование, нарушение которого делает автоматический анализ ненадёжным.

Ключевые принципы организации табличных данных:

- **Одна таблица — один тип сущности.** Нельзя смешивать в одном листе разнородные записи (например, sales и employees): это затрудняет фильтрацию, агрегацию и импорт в базы данных.
- **Заголовки столбцов — отдельная строка, без объединённых ячеек.** Объединённые ячейки — главный враг машинного чтения: pandas, R и SQL-импортёры неверно определяют границы колонок.
- **Типизация столбцов.** Дата должна быть датой, число — числом, а не текстом с пробелами и запятыми. Смешанные типы в столбце ведут к ошибкам при агрегации.
- **Отсутствие «итоговых» строк внутри данных.** Строки «Итого» и «Всего» должны быть вынесены за пределы таблицы данных или вычисляться формулами, иначе они попадут в выборку как обычные наблюдения.

Для исследовательской работы полезно ориентироваться на принципы **tidy data**: каждая переменная — столбец, каждое наблюдение — строка, каждый тип observational unit — отдельная таблица.

2.2. Форматы хранения и обмена: риски потерь при конвертации

Основные форматы хранения и обмена табличными данными и их компромиссы приведены в таблице 1.

Формат	Назначение	Что теряется
XLSX / ODS	Рабочий формат, сохранение формул и форматирования	Плохо читается сторонними скриптами без библиотек; избыточен для обмена «голыми» данными
CSV	Универсальный обмен, архивирование	Теряются формулы, макросы, форматирование, типы данных, метаданные
JSON / XML	Обмен с веб-сервисами, API	Многословность; риск потери типов при нестрогой схеме

Таблица 1. Форматы хранения и обмена табличными данными

Наиболее критичные риски при конвертации (особенно Excel → CSV):

1. **Потеря формул и макросов.** CSV сохраняет только вычисленные значения. Если формула была нужна для воспроизводимости, она исчезает безвозвратно.
2. **Проблемы с кодировкой.** Русскоязычный Excel по умолчанию может использовать Windows-1251 и точку с запятой как разделитель. При открытии такого файла в Python (pandas) или на Linux-сервере кириллица превращается в «кракозябры», а структура колонок ломается.
3. **Смещение колонок из-за разделителей внутри значений.** Если текст содержит запятую или точку с запятой без корректного экранирования, парсер разобьёт одну ячейку на несколько, и вся строка сместится.
4. **Потеря определений пропущенных значений.** В SPSS пропуск может быть закодирован как −99; в CSV это станет просто числом −99, и анализ воспримет его как реальное значение.
5. **Усечение данных.** Ограничения на длину поля или ошибки кодировки могут обрезать текст без предупреждения.

Практическая рекомендация: при конвертации выполнять проверки после миграции — число строк, длина текстовых полей, сохранность специальных символов, наличие всех листов. Для архивирования данных лучше хранить «сырой» CSV в UTF-8 отдельно от рабочего XLSX с формулами.