Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение высшего образования
СИБИРСКИЙ ФЕДЕРАЛЬНЫЙ УНИВЕРСИТЕТ

Гуманитарный институт
Кафедра информационных технологий в креативных и культурных индустриях

РЕФЕРАТ
по дисциплине «Информационные системы и технологии»
на тему:
Технологии создания и обработки табличных данных

Преподаватель — Нигматуллин Илья Рафаильевич

Студент(ы)
Группа: ГФ26-02Б

Стрельская Екатерина Евгеньевна,
Рыженкова Ксения Максимовна,
Новикова Виктория Александровна,
Савельева Анна

Красноярск 2026

СОДЕРЖАНИЕ

ВВЕДЕНИЕ 3
1 Структура табличных данных: принципы организации для машинной обработки 3
2 Форматы хранения и обмена табличными данными: риски потерь при конвертации 4
3 Визуализация табличных данных: выбор формы представления и проблема искажений 5
4 Формулы и функции электронных таблиц: автоматизация расчётов и контроль ошибок 5
5 Очистка и подготовка табличных данных к анализу 6
6 Электронные таблицы в учебной и исследовательской работе: возможности и пределы применимости 8
ЗАКЛЮЧЕНИЕ 9
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ 10

ВВЕДЕНИЕ

Табличные данные — одна из базовых форм представления информации, с которой сталкивается и исследователь, и аналитик, и специалист в креативных индустриях. Электронные таблицы позволяют быстро ввести данные, выполнить расчёт и построить диаграмму, однако за кажущейся простотой скрывается целый набор требований к структуре, форматам хранения и контролю ошибок, от которых зависит корректность любых выводов.

Цель настоящей работы — рассмотреть технологии создания и обработки табличных данных. Для достижения цели поставлены следующие задачи:

– определить принципы организации табличных данных для машинной обработки;

– сравнить форматы хранения и обмена и оценить риски потерь при конвертации;

– рассмотреть формы визуализации и проблему искажений;

– описать автоматизацию расчётов формулами и контроль ошибок;

– раскрыть этапы очистки и подготовки данных к анализу;

– определить возможности и пределы применимости электронных таблиц в учебной и исследовательской работе.

Объект исследования — табличные данные как форма представления информации. Предмет — технологии их создания, хранения, обработки и визуализации.

СТРУКТУРА ТАБЛИЧНЫХ ДАННЫХ: ПРИНЦИПЫ ОРГАНИЗАЦИИ ДЛЯ МАШИННОЙ ОБРАБОТКИ

Табличные данные, предназначенные для машинной обработки, принципиально отличаются от таблиц, созданных исключительно для визуального восприятия человеком. Если человек легко прощает объединённые ячейки, многоуровневые заголовки и цветовое кодирование, то алгоритм требует строгой регулярности: каждая строка должна представлять одно наблюдение, каждый столбец — одну переменную с фиксированным типом данных.

Базовый принцип организации — так называемая «аккуратная» (tidy) структура, при которой таблица имеет плоскую иерархию: одна строка заголовка, отсутствие пропусков в ключевых полях, единый формат для каждого столбца. Нарушение этого принципа — например, когда в одной колонке смешаны числа и текст или когда итоговая строка встроена в тело таблицы —

приводит к тому, что при автоматическом чтении тип столбца определяется неверно, а агрегатные операции дают искажённый результат.

С точки зрения машинной обработки критично и то, что таблица должна быть самоописываемой: наличие заголовков, явное указание единиц измерения, отсутствие скрытых листов и внешних связей. Именно поэтому при подготовке данных к анализу рекомендуется предварительно «нормализовать» таблицу: привести имена столбцов к единому регистру и стилю, удалить пустые строки и столбцы, отделить заголовки от данных. Библиотеки подготовки данных, такие как Datra или tidytable, реализуют эти операции автоматически, подчёркивая, что качественная структура — это не эстетическое требование, а условие корректности последующих вычислений [4].

Таким образом, структура табличных данных для машинной обработки строится на трёх принципах: атомарность наблюдений, типовая однородность столбцов и отсутствие встроенной в тело таблицы служебной информации.

ФОРМАТЫ ХРАНЕНИЯ И ОБМЕНА ТАБЛИЧНЫМИ ДАННЫМИ: РИСКИ ПОТЕРЬ ПРИ КОНВЕРТАЦИИ

Выбор формата хранения и обмена — это всегда компромисс между выразительностью и переносимостью. Наиболее распространённые форматы — XLSX, CSV, JSON и XML — обладают разной устойчивостью к потерям при конвертации.

Критический этап — экспорт из Excel в CSV. Excel хранит не только значения, но и формулы, форматирование, комментарии, проверки данных и типы. CSV сохраняет только «голые» строки, и вся семантическая нагрузка теряется безвозвратно. Более того, русскоязычная версия Excel по умолчанию использует кодировку Windows-1251 и разделитель «точка с запятой», что расходится с международным стандартом RFC 4180 (запятая, UTF-8) [1]. При чтении такого файла в Python или на Linux-сервере кириллица превращается в нечитаемые символы, а структура колонок нарушается.

CSV также крайне чувствителен к синтаксическим повреждениям: пропущенная кавычка в поле с запятой внутри сдвигает все последующие колонки, и восстановить исходное выравнивание без ручной проверки невозможно. JSON, напротив, имеет строгий синтаксис, но любой пропуск скобки или запятой делает невалидным весь документ — частичное чтение невозможно. Excel-файлы устойчивее к частичным повреждениям за счёт бинарной структуры, но их сложнее обрабатывать программно без специализированных библиотек.

Отдельный класс рисков — потеря метаданных: определения пропущенных значений, форматы дат, точность чисел с плавающей точкой. При конвертации между статистическими пакетами и текстовыми форматами метки переменных и значений могут исчезнуть или усечься. Практическая рекомен-

дация: для обмена использовать CSV с явным указанием кодировки UTF-8 и разделителя, для долгосрочного хранения — открытые форматы с сохранением схемы (например, Parquet или JSON с метаописанием), а конвертацию всегда сопровождать проверкой контрольных сумм и выборочным сравнением до и после.

ВИЗУАЛИЗАЦИЯ ТАБЛИЧНЫХ ДАННЫХ: ВЫБОР ФОРМЫ ПРЕДСТАВЛЕНИЯ И ПРОБЛЕМА ИСКАЖЕНИЙ

Визуализация табличных данных решает две противоположные задачи: сделать закономерности видимыми и не солгать при этом. Выбор формы представления зависит от типа данных и вопроса, на который должна ответить визуализация. Для категориальных данных с малым числом категорий подходит столбчатая диаграмма; для распределения — гистограмма или ящик с усами; для связи двух количественных переменных — точечная диаграмма; для временных рядов — линейный график.

Проблема искажений возникает на нескольких уровнях. Первый — масштаб оси. Обрезанная ось Y (например, начинающаяся не с нуля, а с 95% максимального значения) визуально преувеличивает незначительные различия. Второй — агрегация. Суммирование или усреднение по слишком крупным группам может скрыть выбросы и создать иллюзию однородности. Третий — перегруженность. Попытка отобразить все переменные сразу приводит к «спагетти-графикам», где закономерности не читаются.

В учебной и исследовательской работе особенно важно различать исследовательскую визуализацию (для себя, для поиска гипотез) и презентационную (для читателя, для доказательства). В первом случае допустимы быстрые, несовершенные графики; во втором требуется сознательный контроль искажений: подписи осей с единицами, указание размера выборки, отказ от трёхмерных эффектов и «нарядных» цветов в пользу различимости. Электронные таблицы предоставляют базовый набор диаграмм, но для серьёзной визуализации табличных данных чаще используют специализированные библиотеки (matplotlib, ggplot2, seaborn), где контроль над осями, масштабом и аннотациями полнее.

ФОРМУЛЫ И ФУНКЦИИ ЭЛЕКТРОННЫХ ТАБЛИЦ: АВТОМАТИЗАЦИЯ РАСЧЁТОВ И КОНТРОЛЬ ОШИБОК

Для устранения этих недостатков применяются стандартные приёмы. Лишние пробе= Формулы и функции электронных таблиц: автоматизация расчётов и контроль ошибок

Формула в электронной таблице — это выражение, которое начинается со знака равенства и описывает вычисление на основе значений ячеек, чисел и

операторов. Например, запись =A1+B1 складывает содержимое двух ячеек, а запись =C2*C3 перемножает их. Главное свойство формулы — её автоматический пересчёт: при изменении исходных данных результат обновляется мгновенно, поэтому таблица превращается из статичного документа в живую расчётную модель.

Функция — это заранее встроенная формула с именем и аргументами, которая выполняет стандартное действие. К базовым относятся функции суммирования СУММ, вычисления среднего СРЗНАЧ, подсчёта количества значений СЧЁТ, поиска наибольшего и наименьшего значений МАКС и МИН. Более сложные — логические (ЕСЛИ, И, ИЛИ), позволяющие программе принимать решения: например, =ЕСЛИ(B2>50;"зачёт";"незачёт") автоматически проставляет оценку в зависимости от условия. Существуют также функции поиска данных (ВПР, ИНДЕКС), работы с текстом, датами и статистикой. Комбинируя функции, можно описывать целые бизнес-процессы — от расчёта заработной платы до анализа продаж.

Автоматизация расчётов достигается за счёт двух приёмов. Первый — относительная и абсолютная адресация: обычная ссылка A1 при копировании формулы сдвигается, а закреплённая знаками доллара A1 остаётся неизменной, что позволяет один раз написать формулу и распространить её на весь столбец. Второй — заполнение по образцу: протянув маркер автозаполнения, пользователь тиражирует вычисления на сотни строк без ручного ввода.

Контроль ошибок — обязательная часть работы с формулами. Если таблица не может выполнить вычисление, она выводит код ошибки: #ЗНАЧ! означает неверный тип данных, #ДЕЛ/0! — деление на ноль, #ССЫЛКА! — ссылку на удалённую ячейку, #ИМЯ? — опечатку в имени функции, #Н/Д — отсутствие искомого значения. Для обработки таких ситуаций применяются специальные средства: функция ЕСЛИОШИБКА подставляет вместо сообщения об ошибке заданный текст или значение, функция ОКРУГЛ устраняет накопление погрешностей округления, а проверка данных ограничивает ввод недопустимых значений в ячейку.

Таким образом, формулы и функции позволяют перевести рутинные вычисления под контроль компьютера: данные вводятся один раз, а все зависимые результаты пересчитываются автоматически, а встроенные средства диагностики помогают вовремя обнаружить и исправить ошибку. Грамотное сочетание этих возможностей превращает электронную таблицу в надёжный инструмент анализа и принятия решений.

ОЧИСТКА И ПОДГОТОВКА ТАБЛИЧНЫХ ДАННЫХ К АНАЛИЗУ

Очистка данных — это этап, предшествующий любому анализу: прежде чем считать итоги, строить диаграммы и делать выводы, таблицу нужно привести к единообразному и достоверному виду. Сырые данные почти всегда

содержат ошибки и помехи: пропуски, дубликаты, разнобой в написании значений, лишние пробелы, неверные форматы чисел и дат. Работа с такими таблицами без подготовки приводит к тому, что формулы и функции выдают неверные результаты, а итоги расчётов искажаются.

К типичным проблемам, которые требуется устранить, относятся следующие: пустые ячейки и пропущенные значения; повторяющиеся строки; смешанные форматы записи одного и того же значения (например, «Москва», «москва» и «Моск.» в одном столбце); числа, сохранённые как текст; даты, записанные по-разному («01.02.2025», «1-2-25», «февраль»); лишние пробелы и невидимые символы; ошибки, внесённые вручную при наборе данных. лы удаляют функцией СЖПРОБЕЛЫ; однотипный регистр текста задают функциями ПРОПИСН, СТРОЧН; функции ЛЕВСИМВ, ПРАВСИМВ, ПСТР позволяют выделить нужную часть текста, например привести артикулы и коды к единому виду. Числа и даты, сохранённые как текст, преобразуют функцией ЗНАЧЕН или через диалоговое окно «Формат ячеек». Пропуски можно заполнить нулями, средними значениями или пометить особым маркером — способ выбирают в зависимости от задачи. Дубликаты находят и удаляют встроенным инструментом удаления дубликатов, а для контроля уникальности значений используют условное форматирование.

После очистки данные приводят к правильной структуре: каждой переменной соответствует один столбец, каждому наблюдению — одна строка, каждому значению — одна ячейка. Строки таблицы сортируют по нужному признаку, диапазону задают «умную таблицу», чтобы формулы и форматирование распространялись автоматически при добавлении новых записей. Если таблица содержит данные из разных источников, их объединяют по общему ключу — например, по коду товара или ФИО — с помощью функций поиска ВПР или ПРОСМОТРХ.

Завершает подготовку проверка качества: убеждаются, что в числовых столбцах нет текста, диапазоны значений соответствуют реальности (возраст человека не может быть 250 лет), итоговые суммы сходятся с контрольными значениями, а формулы выдают ожидаемые результаты. Только после такой подготовки данные пригодны для анализа: сводные таблицы, статистические функции и диаграммы на очищенных данных дают достоверную картину, а решения, принятые на их основе, — обоснованными.

Таким образом, очистка и подготовка данных — обязательный этап аналитического процесса: он занимает заметную долю времени, но именно он определяет качество всех последующих расчётов и выводов. Третий слой — содержательная очистка: обработка пропущенных значений, дубликатов и выбросов. Здесь нет универсального рецепта: удаление строк с пропусками допустимо при малой доле пропусков и случайном характере их возникновения; заполнение медианой или модой — компромисс, который нужно явно документировать. Дубликаты могут быть полными (одинаковые строки) или

частичными (одинаковый идентификатор с разными датами) — во втором случае правило разрешения конфликта должно быть определено до очистки [4].

Ключевой принцип: очистка должна быть воспроизводимой и документированной. Каждое преобразование — замена пропусков, удаление выбросов, переименование категорий — фиксируется в скрипте или отчёте, чтобы результат можно было проверить и повторить.

ЭЛЕКТРОННЫЕ ТАБЛИЦЫ В УЧЕБНОЙ И ИССЛЕДОВАТЕЛЬСКОЙ РАБОТЕ: ВОЗМОЖНОСТИ И ПРЕДЕЛЫ ПРИМЕНИМОСТИ

Электронные таблицы занимают уникальную нишу в учебной и исследовательской работе благодаря низкому порогу входа и мгновенной обратной связи. Студент, впервые сталкивающийся с данными, может ввести числа, построить диаграмму и увидеть результат за минуты, не изучая синтаксис языка программирования. Для небольших наборов данных (сотни, иногда тысячи строк) Excel или LibreOffice Calc остаются адекватным инструментом разведочного анализа, построения сводных таблиц и подготовки иллюстраций.

Однако пределы применимости начинаются там, где заканчивается «небольшой набор». Электронные таблицы плохо масштабируются: при десятках тысяч строк производительность падает, а вероятность случайного изменения ячейки возрастает. Отсутствие версионного контроля в привычном смысле (история изменений в Excel есть, но она не заменяет Git) делает совместную работу рискованной: две версии файла с одинаковым именем могут содержать разные данные. Формулы, разбросанные по ячейкам, труднее проверить и воспроизвести, чем скрипт: в скрипте виден весь конвейер обработки, в таблице — только конечный результат.

Для исследовательской работы критично и то, что электронные таблицы поощряют неявные решения. Сортировка, выполненная мышью, не оставляет следа; фильтр, скрывший часть строк, может быть забыт; «подчистка» выбросов вручную недокументируема. Воспроизводимость — базовое требование научного исследования — страдает.

Разумная стратегия: использовать электронные таблицы на этапе сбора, первичного осмотра и визуализации, но переносить обработку в скрипты (Python, R) по мере роста сложности. Таблицы хороши как блокнот и как средство коммуникации с неспециалистами; они плохи как среда для воспроизводимого анализа. Понимание этой границы — часть цифровой грамотности, которую и должен формировать учебный курс.

ЗАКЛЮЧЕНИЕ

В работе рассмотрены технологии создания и обработки табличных данных. Показано, что структура таблицы для машинной обработки строится на атомарности наблюдений, типовой однородности столбцов и отсутствии служебной информации в теле таблицы. Сравнение форматов хранения и обмена выявило, что экспорт в CSV сопряжён с потерями семантики и рисками кодировки, а конвертацию необходимо сопровождать проверкой. Рассмотрены формы визуализации и источники искажений, практики контроля ошибок формул, а также трёхслойная модель очистки данных — структурная, типовая и содержательная. Сделан вывод о разумной стратегии: электронные таблицы эффективны на этапе сбора, первичного осмотра и визуализации, тогда как воспроизводимый анализ требует переноса обработки в скрипты.

Поставленные задачи выполнены, цель работы достигнута.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Shafranovich Y. Common Format and MIME Type for Comma-Separated Values (CSV) Files. RFC 4180, IETF, 2005. URL: https://www.rfc-editor.org/rfc/rfc4180.html (дата обращения: 08.11.2026).
2. Microsoft Support. Fix an inconsistent formula. URL: https://api.support.office.com/zh-cn/article-5dd940a1-4f87-44bd-91dd-bf45ed828f05 (дата обращения: 08.11.2026).
3. Microsoft Support. Detect formula errors in Excel. URL: https://support.microsoft.com/ar-sa/Excel/detect-formula-errors-in-excel (дата обращения: 08.11.2026).
4. PyPI. datra 0.1.0. URL: https://pypi.org/project/datra/ (дата обращения: 08.11.2026).
5. Fairbanks M. Package {tidytable}. CRAN. URL: https://cran.r-project.org/web/packages/tidytable/DESCRIPTION (дата обращения: 08.11.2026).